國立中正大學電機工程研究所

醫學影像專題 專題一

阿茲海默症四類影像分類

Alzheimers 4-Class Classification

組員：

614415072 林裕翔

614415075 顏苡亘

614415107 黃品甄

授課教授：林維暘 博士

中華民國 一百一十五年四月

摘要

本研究旨在開發一套自動化分類系統，針對 Kaggle 上公開資料集，Alzheimers 4-Class Classification Dataset，腦部 MRI 影像進行阿茲海默症四種病理階段的精確辨識 。研究路徑從基礎的卷積神經網路（AlzheimerCNN）出發，透過分析訓練過程中的不穩定性，逐步導入殘差結構（ResNet）、倒置殘差與編碼技術（EfficientNet）、多尺度特徵提取（GoogLeNet）以及最新的卷積架構（ConvNeXt） 。結合遷移學習與多樣化的資料增強策略，本研究成功解決了醫療影像樣本不均與過擬合的問題，將測試準確率從初期的 88%大幅提升至 99%以上 。本研究證實了遷移學習與先進卷積架構在小型醫療資料集上的巨大價值 。透過 ImageNet 預訓練權重的特徵提取能力，搭配餘弦退火等策略解決訓練不穩問題，最終建立了一個具備高穩定性與高準確度的阿茲海默症輔助診斷系統 。

關鍵字：阿茲海默症、醫療影像分類、遷移學習、資料增強、卷積神經網路 、ResNet、EfficientNet、GoogLeNet、ConvNeXt

ABSTRACT

This study aims to develop an automated classification system for accurately identifying the four pathological stages of Alzheimer's disease using publicly available datasets on Kaggle, the Alzheimer's 4-Class Classification Dataset, and brain MRI images. The research approach starts with basic convolutional neural networks (AlzheimerCNN), and through analyzing instability during training, gradually incorporates residual structures (ResNet), inverted residual and encoding techniques (EfficientNet), multi-scale feature extraction (GoogLeNet), and the latest convolutional architecture (ConvNeXt). By combining transfer learning and diverse data augmentation strategies, this study successfully addresses the issues of uneven medical image sample distribution and overfitting, significantly improving the test accuracy from an initial 88% to over 99%. This study demonstrates the significant value of transfer learning and advanced convolutional architectures on small medical datasets. By leveraging the feature extraction capabilities of ImageNet pre-trained weights, combined with strategies such as cosine annealing to address training instability, a highly stable and accurate Alzheimer's disease auxiliary diagnostic system was ultimately established.

Keywords: Alzheimer's disease, medical image classification, convolutional neural networks (CNN), transfer learning, ResNet, EfficientNet, GoogLeNet, ConvNeXt, data augmentation

目錄

摘要.....i
ABTRACT.....ii
目錄.....iii
圖目錄.....v
表目錄.....vi
第一章 緒論.....1
1.1 研究背景與動機.....1
1.2 研究目的.....1
1.3 核心方法與研究流程.....2
1.4 本章小結.....2
第二章 研究背景.....3
2.1 阿茲海默症.....3
2.2 磁振造影.....3
2.3 卷積神經網路.....3
2.4 殘差學習網路.....4
2.5 EfficientNet.....5
2.6 GoogLeNet.....6
2.7 ConvNeXt.....7
第三章 研究方法.....9
3.1 資料集.....9
3.2 資料前處理.....9
3.3 模型效能評估指標.....10

3.4 模型訓練參數 11
3.5 硬體設備及軟體環境 11
第四章 實驗結果 12
4.1 阿茲海默症腦部 MRI 影像四分類任務 12
4.2 模型總合比較 15
4.3 Grad-CAM 18
第五章 結論 21
5.1 研究總結 21
5.2 技術貢獻與發現 21
5.3 未來展望 22
參考資料 23

圖目錄

圖 2-1 Residual block 4

圖 2-2 **Left**: a building block；**Right**: a “bottleneck” building block 4

圖 2-3 Training on CIFAR-10. **Left**: plain networks；**Right**: ResNets 5

圖 2-4 Inception 模塊 6

圖 2-5 ConvNeXt – Tiny 架構 8

圖 3-1 Confusion Matrix schematic diagram 10

圖 4-1 AlzheimerCNN2 13

圖 4-2 ResNet50 13

圖 4-3 ResNet101 13

圖 4-4 EfficientNet 14

圖 4-5 GoogLeNet 14

圖 4-6 ConvNeXt 14

圖 4-7 AlzheimerCNN2 Confusion Matrix 15

圖 4-8 ResNet50 Confusion Matrix 16

圖 4-9 ResNet101 Confusion Matrix 16

圖 4-10 EfficientNet-B0 Confusion Matrix 16

圖 4-11 GoogLeNet Confusion Matrix 17

圖 4-12 ConvNeXt Confusion Matrix 17

圖 4-13 NonDemented Heatmap 19

圖 4-14 VeryMildDemented Heatmap 19

圖 4-15 MildDemented Heatmap 20

圖 4-16 ModerateDemented Heatmap 20

表目錄

表 2-1 Error rates (%) on the ImageNet validation set 5

表 2-2 EfficientNet 架構..... 6

表 3-1 Dataset 9

表 3-2 Model training Hyper-Parameters 11

表 3-3 Hardware Specification 11

表 3-4 Software Environment..... 11

表 4-1 各模型效能指標 17

表 4-2 各模型綜合比較 18

第一章 緒論

1.1 研究背景與動機

阿茲海默症（Alzheimer's Disease, AD）是一種不可逆的腦部疾病，臨床上以認知功能衰退、記憶力喪失及行為改變為主要特徵。隨著全球高齡化社會的到來，失智症的早期診斷與分期對於臨床治療及病患照護顯得至關重要。醫學影像技術，特別是磁振造影（MRI），已成為臨床診斷 AD 的核心工具，透過觀察腦部結構，如腦室擴大或皮質萎縮的變化，協助醫師評估病情。然而，僅憑人工判讀 MRI 影像不僅耗時，且在病徵微弱的極輕度階段（Very Mild Demented）極易產生診斷誤差。因此，開發一套高準確度的自動化影像分類系統，成為當前醫學影像處理領域的重要課題。

1.2 研究目的

本研究旨在針對 Kaggle 公開資料集中的腦部 MRI 影像，開發一套基於深度學習的四階段自動化分類輔助系統。研究目標是精確區分以下四種病理階段：

- Non Demented（無失智）
- Very Mild Demented（極輕度失智）
- Mild Demented（輕度失智）
- Moderate Demented（中度失智）

本研究將從基礎的卷積神經網路（Baseline CNN）出發，探討不同深度學習架構在醫療影像上的表現差異，並導入多樣化的優化策略以解決訓練不穩及過擬合的問題。

1.3 核心方法與研究流程

本研究的路徑規劃由淺入深，透過實驗演進驗證各項技術的有效性：

架構演進：由基礎的 AlzheimerCNN 逐步升級至 ResNet50、ResNet101、GoogLeNet、EfficientNet，以及最新的 ConvNeXt 架構，旨在提取更高品質的病理特徵。

訓練策略優化：利用遷移學習技術，導入在 ImageNet 大型數據集上預訓練的權重，使模型在小型醫療數據集上仍能有效學習。

資料處理技術：實施多樣化的資料增強，包括隨機水平翻轉、小角度旋轉及亮度調整，以增強模型的泛化能力。

優化演算法：搭配餘弦退火學習率調度策略與 AdamW 優化器，確保模型訓練的穩定性與收斂效果。

1.4 本章小結

本章簡述了阿茲海默症自動化分類的研究動機與背景，確立了以深度學習技術輔助醫療診斷的研究目標。後續章節將詳細說明資料庫建立、實驗環境配置、模型架構設計，並透過實驗數據與 Grad-CAM 可視化結果驗證系統的準確性與穩定性。

第二章 研究背景

2.1 阿茲海默症

阿茲海默症(Alzheimer's Disease，簡稱 AD)[1]是一種慢性神經退化性疾病，約佔失智症案例中的 60%至 80% 。其病理特徵包括大腦神經元受損與喪失，導致病患在認知功能、記憶能力及行為調節上出現顯著退化 。臨床上通常根據病情的嚴重程度，將其細分為輕度 (Mild)、中度 (Moderate)、極輕度 (Very Mild) 及無症狀 (Non-Demented) 等不同病理階段進行分類與治療規劃 。

2.2 磁振造影

磁振造影（Magnetic Resonance Imaging, MRI）是目前診斷阿茲海默症最核心的醫學影像技術之一 。透過高品質的腦部切面影像，醫師可以觀察到大腦結構的細微變化，例如腦室擴大或大腦皮質萎縮等關鍵病理特徵 。在深度學習的研究中，MRI 影像提供了豐富的空間紋理資訊，是模型提取病理特徵的重要來源 。

2.3 卷積神經網路

卷積神經網路（Convolutional Neural Network, CNN）是專為處理具備格狀結構數據所設計的深度學習模型 。CNN 的發展始於 1980 年福島邦彥提出的 Neocognitron，奠定了感受野的概念。1998 年，Yann LeCun 提出 LeNet-5[2]，正式確立了卷積、池化與全連接層的經典架構，並成功應用於手寫數字辨識。沉寂多年後，2012 年 AlexNet[3]藉由 GPU 算力與 ImageNet 大數據奪冠，開啟深度學習熱潮。而 CNN 最重要的核心組件包含，卷積層，利用濾波器提取影像中的邊緣、紋理等局部特徵 。池化層，降低特徵圖維度，減少計算量並維持特徵位移的不變性 。全連接層，整合高階特徵以進行最終類別的決策分類 。

2.4 殘差學習網路

ResNet (Residual Network)是 K. He 等人在 2016 年提出的模型[4]，透過殘差解決梯度消失及網路退化的問題，在深層的網路不會取得比淺層網路還差的結果。其中殘差學習是考慮 CNN 中的一小部分，輸入為 x，映射結果為 H(x)-x，將 H(x)-x 稱 F(x)，最終將 F(x)與 x 相加，如圖 2-1。所示，原本 Weight Layer 是輸出 Feature map，但在殘差網路中，Weight Layer 則是輸出最終 Feature map 和輸入特徵的差值 F(x)，另外，圖 2-1 中的短路連接(shortcut connection)跨接兩個 Weight Layer，在實際使用時，可以跨接多個卷積層。

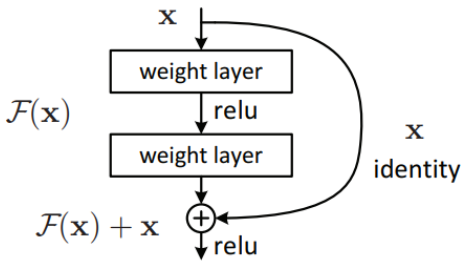

圖 2-1 Residual block

ResNet 的結構可以分成兩類，如圖 2-2 所示，在深層的網路通常會採用圖 2-2 右邊的型式以減少計算量，ResNet50 便是採用此方法，首先由1 × 1卷積降低通道數，再進行3 × 3卷積的特徵提取，最後用1 × 1進行通道數的擴增。

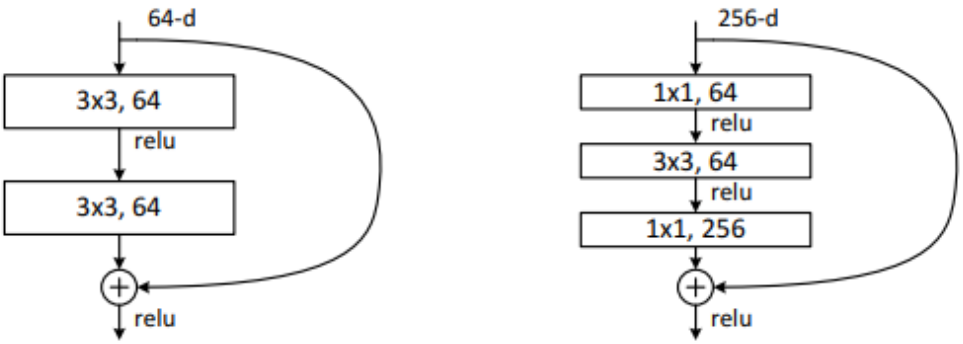

圖 2-2 **Left**: a building block；**Right**: a “bottleneck” building block

提出此架構的作者也針對其進行兩種數據集的測試，圖 2-3 為 CIFAR-10 數據集的測試結果，左邊部分是傳統的 CNN 架構，其錯誤率並不會隨著網路層數

的疊加而有所改善，甚至在越深層的網路效果越糟糕，右邊部分採 ResNet 網路架構測試，很明顯隨著網路層數的增加，錯誤率也能隨之降低。表 2-1 則是用不同常見的模型在 ImageNet 數據集測試結果，ResNet 的架構中，與其他網路架構比較上有顯著的差異。

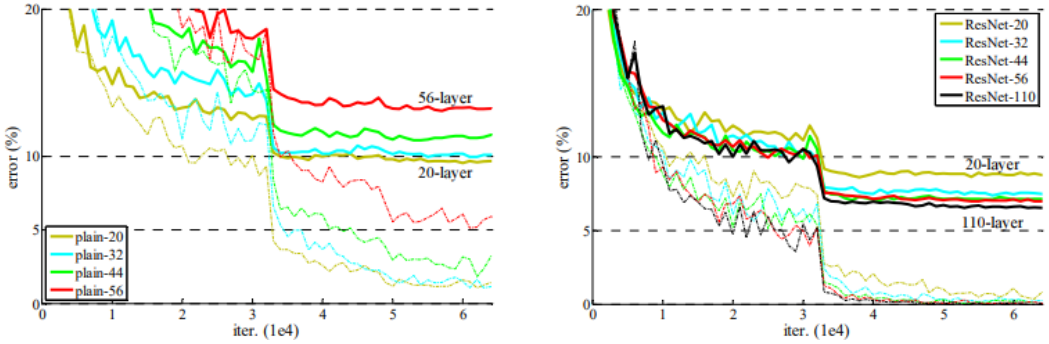

圖 2-3 Training on CIFAR-10. **Left**: plain networks；**Right**: ResNets

表 2-1 Error rates (%) on the ImageNet validation set

method	top-1 err.	top-5 err.
VGG [41] (ILSVRC'14)	-	8.43†
GoogLeNet [44] (ILSVRC'14)	-	7.89
VGG [41] (v5)	24.4	7.1
PReLU-net [13]	21.59	5.71
BN-inception [16]	21.99	5.81
ResNet-34 B	21.84	5.71
ResNet-34 C	21.53	5.60
ResNet-50	20.74	5.25

2.5 EfficientNet

EfficientNet，由 Google Research 團隊，Mingxing Tan 與 Quoc V. Le 等人提出[5]。是由 Google 開發的一種追求效率與性能平衡的模型，其核心概念是複合縮放。不同於以往模型僅單純增加深度或寬度，從表 2-2 可以看到 EfficientNet 透過一個複合係數同時調整網路深度、寬度與輸入影像解析度 。其基礎模組 MBConv 採用了倒置殘差結構與線性瓶頸，並結合了注意力機制來加強重要特徵。本研究使用 EfficientNet-B0(以下簡稱 EfficientNet)，的優勢在於參數效率極高，能以較小的運算量達到頂尖的準確度，適合作為計算資源有限環境下的首選；但其缺點在於複雜的縮放規則有時會導致在特定硬體上的推理速度不如預

期 。

表 2-2 EfficientNet 架構

Stage i	Operator $\hat{\mathcal{F}}_i$	Resolution $\hat{H}_i \times \hat{W}_i$	#Channels $\hat{C}_i$	#Layers $\hat{L}_i$
1	Conv3x3	224×224	32	1
2	MBConv1, k3x3	112×112	16	1
3	MBConv6, k3x3	112×112	24	2
4	MBConv6, k5x5	56×56	40	2
5	MBConv6, k3x3	28×28	80	3
6	MBConv6, k5x5	14×14	112	3
7	MBConv6, k5x5	14×14	192	4
8	MBConv6, k3x3	7×7	320	1
9	Conv1x1 & Pooling & FC	7×7	1280	1

2.6 GoogLeNet

GoogLeNet，亦稱為 Inception 網路，主要由 Google 團隊開發，核心作者為 Christian Szegedy 等人[6]，其設計初衷是為了在增加網路深度與寬度的同時維持計算預算不變 。該架構引入了 Inception 模組，在同一層中並行使用不同尺寸（如: 1×1, 3×3, 5×5）的卷積核來提取多尺度的空間資訊 。這種多尺度設計使其在捕捉醫療影像中不同大小的病變特徵時具有天然優勢 。此外，它還利用了輔助分類器（Auxiliary Classifiers）在訓練階段強化梯度傳導 。

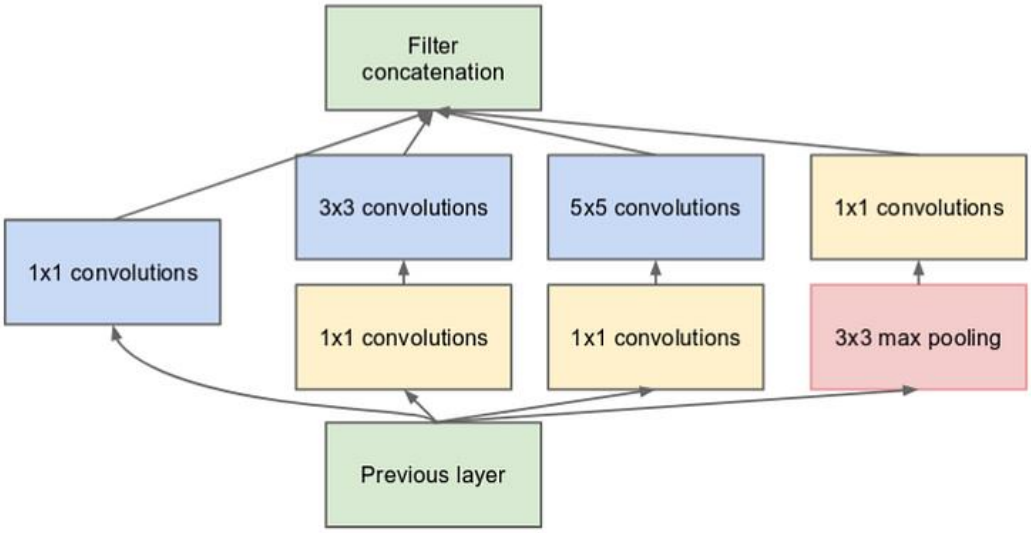

圖 2-4 Inception 模塊

從圖 2-4 中 GoogLeNet 得主架構 Inception 模塊主要由以下四個分支所構建

(1) 分支 1（1x1 卷積）：

這個分支的目的是用來進行通道數的降維，降低計算量，並提取特徵。

(2) 分支 2（1x1 後接 3x3 卷積）：

這個分支能夠捕捉較小的空間特徵，並增加模型的非線性表達能力。

(3) 分支 3（1x1 後接 5x5 卷積）：

這個分支的目的是捕捉更大的空間特徵，通常用來處理較大的物體。

(4) 分支 4（3x3 最大池化後接 1x1 卷積）：

通過最大池化來降低特徵圖的維度，然後使用 1x1 卷積來增加模型的表達能力。

這些分支的輸出會在通道維度上進行拼接，形成最終的特徵表示。而本研究所採用 GoogLeNet InceptionV3(以下簡稱為 GoogLeNet)作為訓練用模型，GoogLeNet 的優點是特徵提取非常全面且參數量適中；缺點則是架構設計較為複雜，靈活性與模組化程度不如 ResNet。

2.7 ConvNeXt

ConvNeXt，由 Meta AI 研究團隊（Zhuang Liu, Hanzi Mao 等）提出[7]，本質上是將經典的 ResNet 架構，參考 Vision Transformer (ViT) 的設計思想進行了現代化改版。旨在證明純卷積網路在現代深度學習任務中仍具競爭力 。它從標準的 ResNet 出發，在架構細節上進行了大幅改進，包括採用較大的深度卷積核（如 7×7）、更少的激活函數與歸一化層，以及使用層歸一化取代批次歸一化。ConvNeXt 的優點在於它保留了卷積層對影像的歸納偏向，同時具備類似 ViT 的強大特徵提取能力，在分類準確度上表現極其穩定 。在本研究中，使用 ConvNeXt-Tiny(以下簡稱為 ConvNeXt)作為最終模型展現了最佳的泛化能力；唯一的潛在劣勢是其對大型數據集預訓練的依賴性較高，但在結合遷移學習後

該缺點被有效克服。

在宏觀設計方面，ConvNeXt 調整了各階段網絡層數的堆疊比例，圖 2-5 中 ConvNeXt 從 ResNet 原有的(3, 4, 6, 3) 優化為更接近 ViT 比例的(3, 3, 9, 3)，並將初始下採樣層替換為 4x4 且步長為 4 的卷積核，以模擬 ViT 的 Patchify 處理方式。

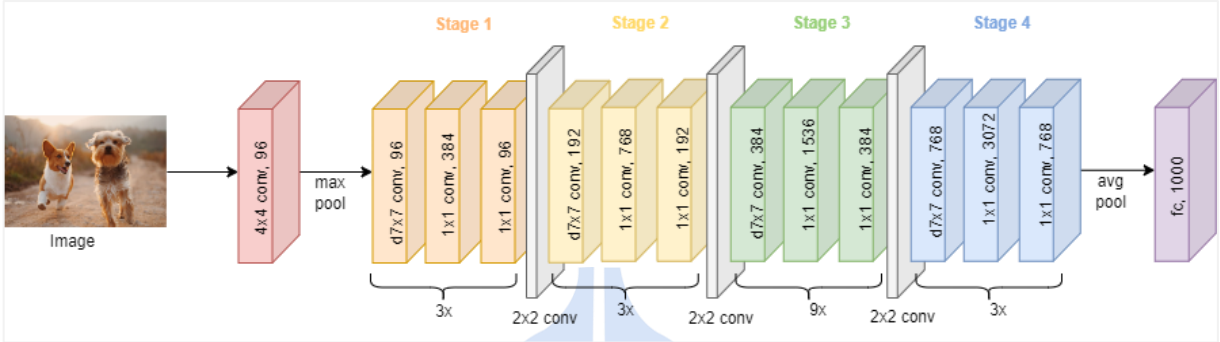

圖 2-5 ConvNeXt – Tiny 架構

為了提升特徵提取能力並控制運算負擔，該架構引入了深度可分離卷積，並將卷積核大小由 3x3 擴大至 7x7，從而獲得與 Transformer 相似的全域感受野。

在微觀設計上，ConvNeXt 採用了倒殘差結構，藉由擴張中間層維度來增強非線性表達。此外，為了優化訓練動態與模型效率，該架構簡化了激活函數與歸一化層的使用，僅在每個 Block 中配置單層 GELU 激活函數與 Layer Normalization (LN)。這種簡約的設計有效減輕了傳統 CNN 中過度繁雜的層級結構，使模型表現出優於 Swin Transformer 的性能。

第三章 研究方法

3.1 資料集

本研究採用來自 Kaggle 公開平台之阿茲海默症腦部 MRI 影像資料集[8]，該資料集包含四種病理階段 。資料集總體依據比例劃分為訓練集（80%）、測試集（10%）及驗證集（10%） 。具體類別分佈如下：無失智 (NonDemented)：包含訓練集 2560 張、測試集 320 張與驗證集 320 張，為資料集中樣本數最多的類別 。極輕度失智 (VeryMildDemented)：包含訓練集 1792 張、測試集 224 張與驗證集 224 張 。輕度失智 (MildDemented)：包含訓練集 716 張、測試集 90 張與驗證集 90 張 。中度失智 (ModerateDemented)：包含訓練集 52 張、測試集 6 張與驗證集 6 張，樣本數最為稀少，存在顯著的類別不平衡問題 。

表 3-1 Dataset

Class	Train (80%)	Test (10%)	Validation (10%)	Total
MildDemented	**716**	**90**	**90**	**906**
ModerateDemented	**52**	**6**	**6**	**64**
NonDemented	**2560**	**320**	**320**	**3200**
VeryMildDemented	**1792**	**224**	**224**	**2240**

3.2 資料前處理

在本研究訓練過程中，我們應用了幾種隨機的數據增強策略，包括(1) 左右翻轉； (2) 小角度旋轉 rotation（± 5°）； (3) 以機率 p = 0.5 隨機水平翻轉圖像； (4) 亮度變化 brightness，模擬不同掃描條件。

3.3 模型效能評估指標

本研究設計了一個用於快速區分阿茲海默症腦部 MRI 影像類別的輕量化模型，對於這項分類任務我們分別對訓練、驗證和測試集使用 8:1:1 的比例隨機拆分。訓練集用於訓練模型，驗證集用於優化超參數以獲得最佳分類效能。最終的最優模型在獨立測試集上進行評估。我們計算了模型分類結果的 Accuracy、Precision、Sensitivity、Specificity 等指標來評估模型效能，所使用到的指標皆由圖 3-1 混淆矩陣數值以下方公式計算得出：

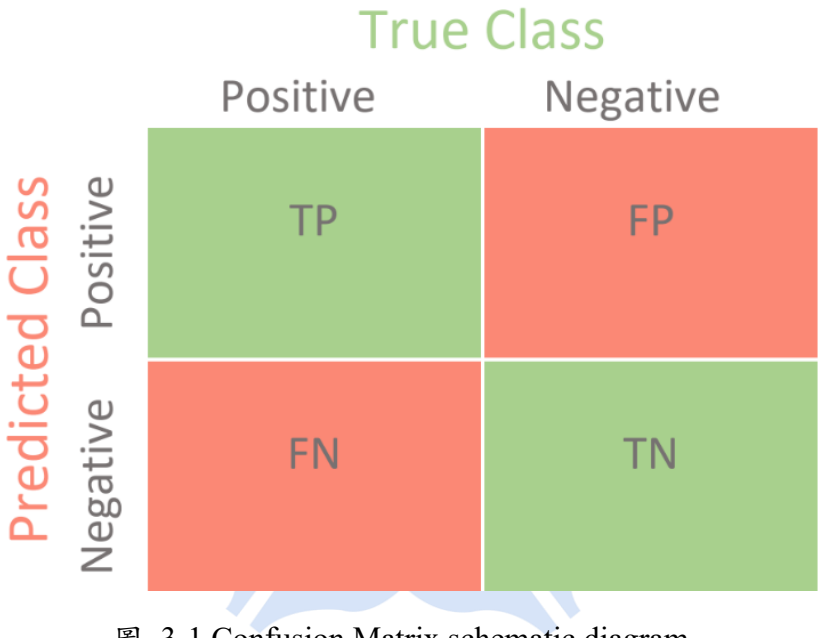

圖 3-1 Confusion Matrix schematic diagram

$$Accuracy = \frac{TP+TN}{TP+FP+TN+FN} \quad (1)$$

$$Precision = \frac{TP}{TP+FP} \quad (2)$$

$$Sensitivity = \frac{TP}{TP+FN} \quad (3)$$

$$Specificity = \frac{TN}{TN+FP} \quad (4)$$

$$F1-score = \frac{2}{Precision+Sensitivity} \quad (5)$$

其中 TP、TN、FP 和 FN 分別為真陽性、真陰性、假陽性和假陰性的數量。同時，我們也繪製了 ROC 曲線並計算 AUC 來量化模型的分類能力。

3.4 模型訓練參數

表 3-2 Model training Hyper-Parameters

Model	ImproveCNN	ResNet50	ResNet101	GoogLeNet	EfficientNet	ConvNeXt
Epoch	25	15	15	15	15	25
Learning Rate	5.00E-05	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04
Optimizer	Adam	Adam	Adam	Adam	Adam	AdamW
Batch Size	32	32	32	32	32	64
Loss Function	CrossEntropy Loss	CrossEntropy Loss	CrossEntropy Loss	CrossEntropy Loss	CrossEntropy Loss	Weighted CrossEntropy Loss

3.5 硬體設備及軟體環境

表 3-3 Hardware Specification

Model	ImproveCNN	ResNet50	ResNet101	GoogLeNet	EfficientNet	ConvNeXt
作業系統 (OS)	Window 10				Window 10	Window 11 企業版
處理器 (CPU)	Intel(R) Core(TM) i7-10500				Intel(R) Core(TM) i5-12450HX	Intel(R) Core(TM) i5-12400
顯示卡 (GPU)	NVIDIA GeForce RTX 2070 Super				NVIDIA GeForce RTX 3050 6GB Laptop GPU	NVIDIA GeForce RTX 3070
記憶體 (RAM)	32 GB				16 GB	32 GB

表 3-4 Software Environment

Model	AlzheimerCNN2	ResNet50	ResNet101	GoogLeNet	EfficientNet	ConvNeXt
Python	3.13.7				3.11.0	3.10.20
PyTorch	2.9.1				2.5.1	2.5.1
CUDA	12.6				12.1	12.1

第四章 實驗結果

為了量化和評估模型的效能，我們計算了標準文獻中定義和比較的指標，如 Accuracy(準確率)、Precision(精確率)、Sensitivity(敏感度)、Specificity(特異度)和 F1 score。

4.1 阿茲海默症腦部 MRI 影像四分類任務

本研究透過對比圖 4-1 至圖 4-6 中依序 AlzheimerCNN2、ResNet (50/101)、EfficientNet、GoogLeNet 及 ConvNeXt 六種不同架構之訓練曲線發現，模型效能與架構演進呈現顯著正相關。

在 AlzheimerCNN2 的圖 4-1 中，Loss 曲線呈現不規則的跳動，這在學術上代表模型陷入了非凸優化的局部陷阱。因為它沒有 ImageNet 的遷移學習基礎，就像一個完全沒看過腦部的初學者，在大量的 MRI 灰階特徵中迷失，導致權重更新方向不穩定。 相比之下，ConvNeXt 的 Loss 曲線呈現完美的 L 型收斂，這得益於其類 Transformer 的大卷積核與 Layer Normalization。這證明了現代架構能更快鎖定腦部萎縮的核心特徵。

在導入 ImageNet 的遷移式學習後，ResNet 圖 4-2 至圖 4-3 與 EfficientNet 圖 4-4 雖然準確率高，但觀察其 F1-Score 曲線，仍可見細微的上下擺動。這反映出模型在面對邊界樣本時仍有遲疑。

GoogLeNet 憑藉其 Inception 多尺度卷積模塊，展現了比傳統 CNN 更穩定的特徵捕捉能力，是實驗中首個呈現穩定趨勢的架構。這歸功於它使用了輔助分類器來協助梯度回傳，防止了深層網路常見的梯度消失問題。雖然它的最終準確率不及 ConvNeXt，但它是這幾組模型中，第一款展現出穩定收斂趨勢的模型。在這些模型中，特別是樣本極少的 ModerateDemented 類別，ConvNeXt 能在 F1-Score 上穩定爬升，正是因為它能承載我們設定的高權重懲罰。反觀在自

定義模型 AlzheimerCNN2 中，高權重往往會導致梯度爆炸使模型崩潰，但現代模型具備強大的殘差連結與優化策略，能將這些懲罰轉化為辨識稀有病例的敏感度。

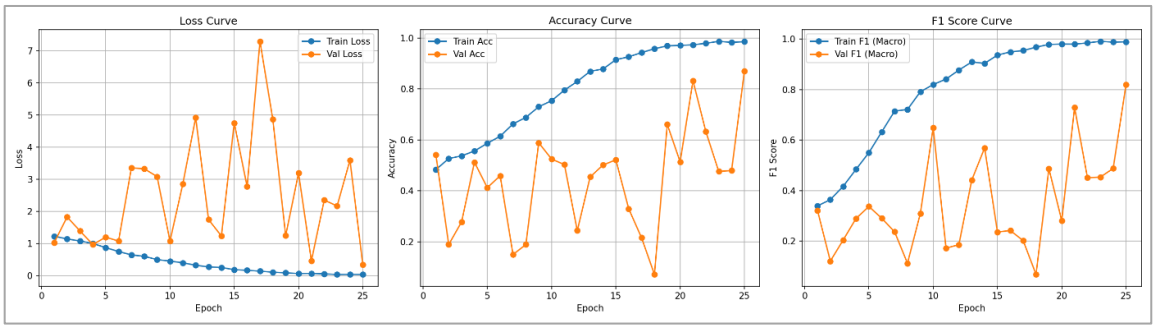

圖 4-1 AlzheimerCNN2

(**Left**: Training Loss；**Middle**: Training Accuracy ; **Right**: F1-Score)

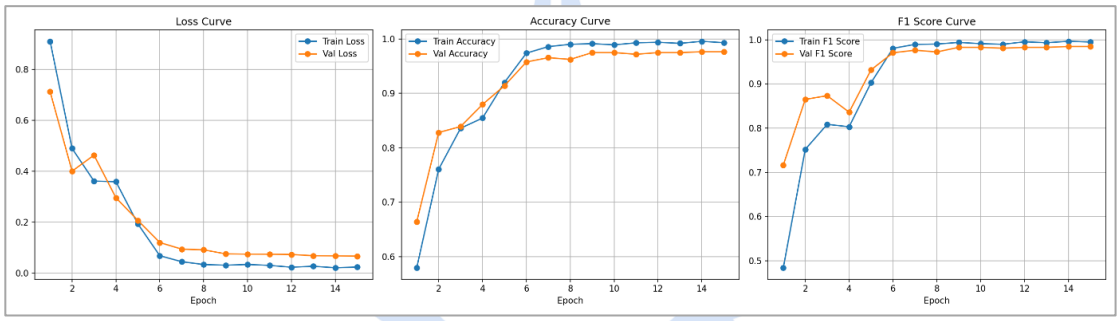

圖 4-2 ResNet50

(**Left**: Training Loss；**Middle**: Training Accuracy ; **Right**: F1-Score)

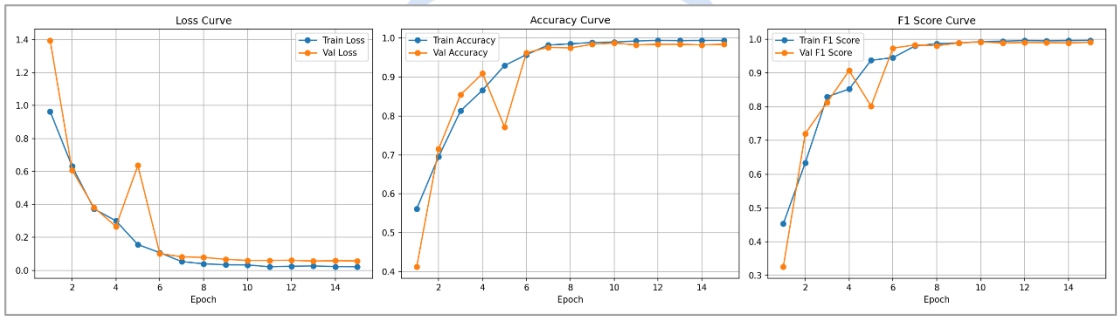

圖 4-3 ResNet101

(**Left**: Training Loss；**Middle**: Training Accuracy ; **Right**: F1-Score)

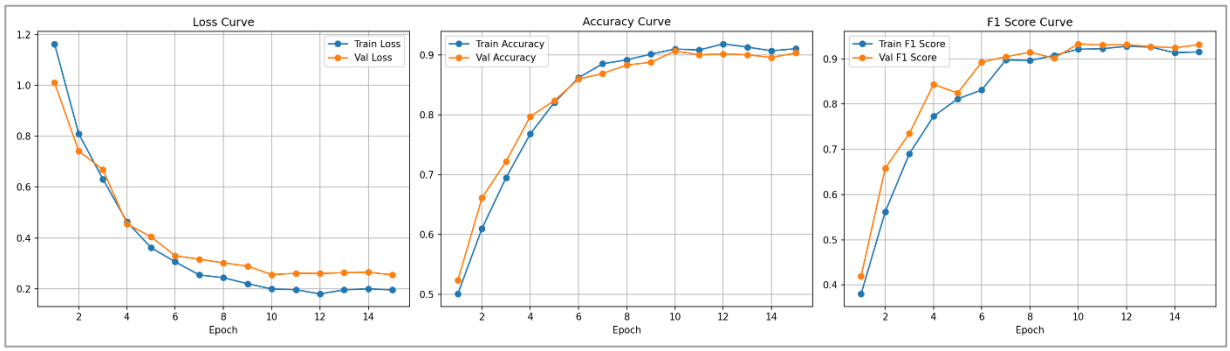

圖 4-4 EfficientNet

(**Left**: Training Loss；**Middle**: Training Accuracy ; **Right**: F1-Score)

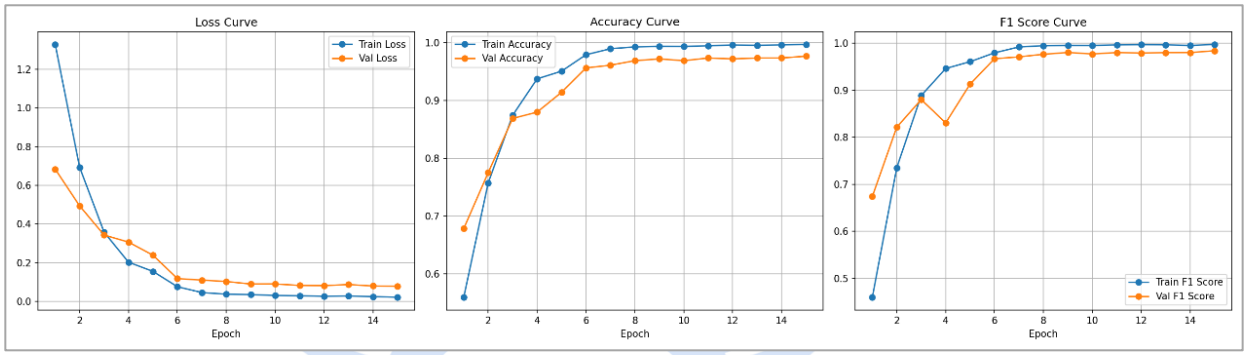

圖 4-5 GoogLeNet

(**Left**: Training Loss；**Middle**: Training Accuracy ; **Right**: F1-Score)

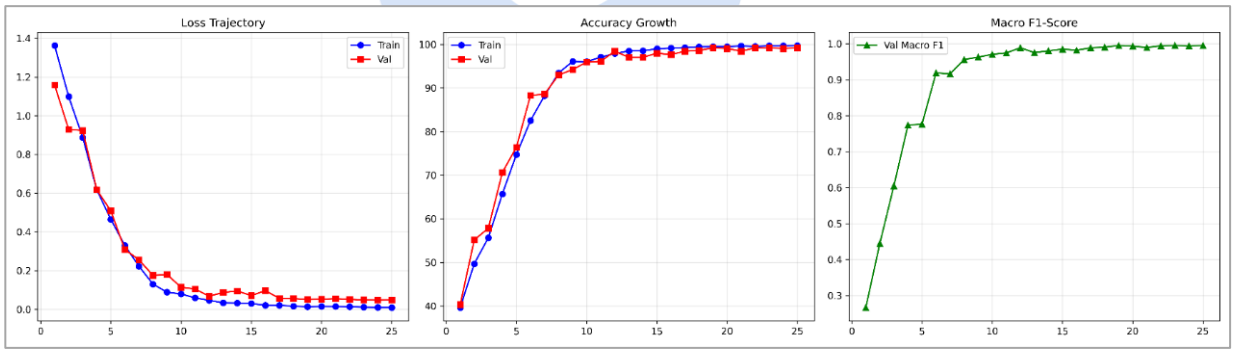

圖 4-6 ConvNeXt

(**Left**: Training Loss；**Middle**: Training Accuracy ; **Right**: Macro F1-Score)

4.2 模型總合比較

由圖 4-7 至圖 4-12 混淆矩陣，以及表 4-1 與表 4-2 實驗數據可知，自定義之 AlzheimerCNN2 雖經由增加卷積層與調整 Dropout 等手段優化，但在各項指標上仍顯著落後於預訓練模型，其 Test F1 僅為 87.70%，證實了在醫療影像這類特徵細微的任務中，遷移學習的重要性。

在經典架構中，ResNet50 與 GoogLeNet 展現了穩定的表現，Test Acc 分別達到 98.40% 與 98.60%。儘管 Resnet101 擁有更深的網路層級，但由於在 MRI 影像分類中可能產生過擬合現象，其 Test Acc 雖然有 97.80%卻反而略低於 ResNet50。而 EfficientNet 在本實驗中的表現相對保守，推測其複合縮放機制在小規模醫療數據集上的優勢尚未完全發揮。

本研究之最優模型為 ConvNeXt - Tiny，其 Test Acc 高達 99.53%，Test F1 達到 99.72%。其成功之關鍵在於複合式的優化策略，Weighted Loss 導入有效解決了資料集中類別不平衡的問題，特別是提升了對少數病例類別的敏感度。全連接層與排程優化，透過降低最後全連接層的複雜度並配合學習率排程，模型成功在收斂後期捕捉到更精細的解剖學特徵。數據增強，大幅提升了模型的泛化能力，使其在獨立測試集上的表現甚至優於驗證集。

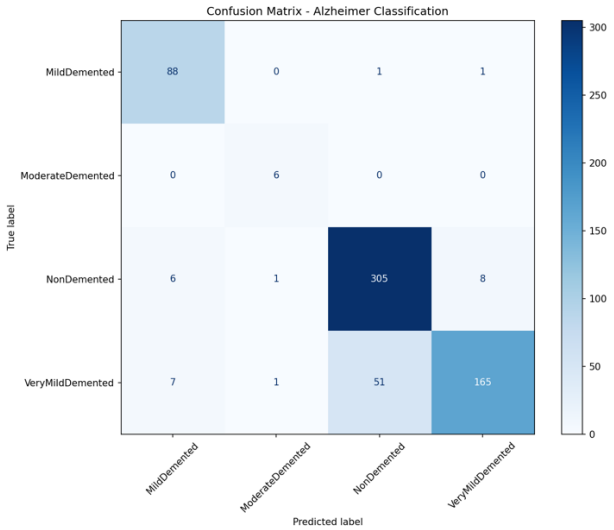

圖 4-7 AlzheimerCNN2 Confusion Matrix

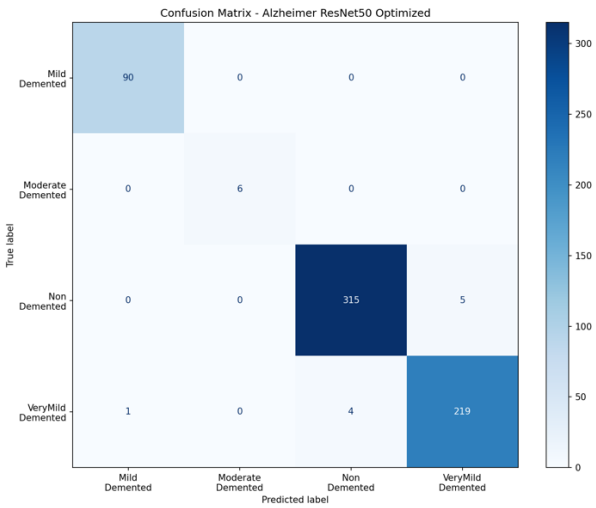

圖 4-8 ResNet50 Confusion Matrix

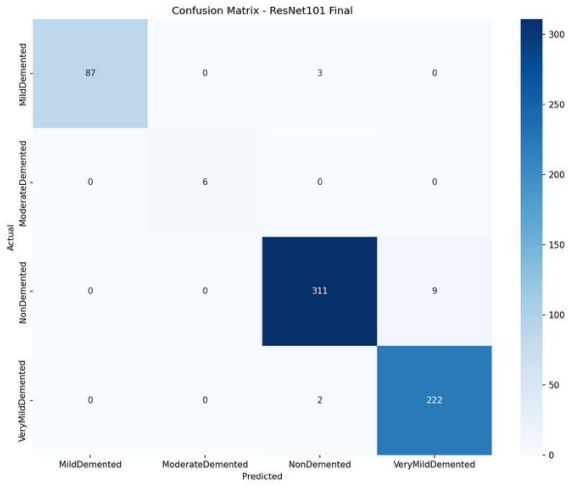

圖 4-9 ResNet101 Confusion Matrix

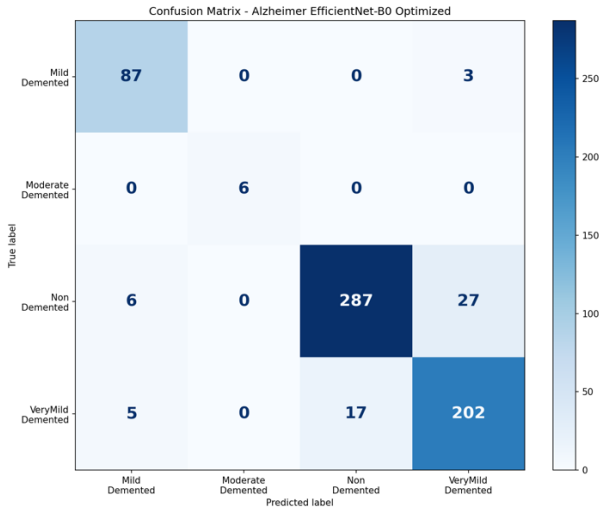

圖 4-10 EfficientNet-B0 Confusion Matrix

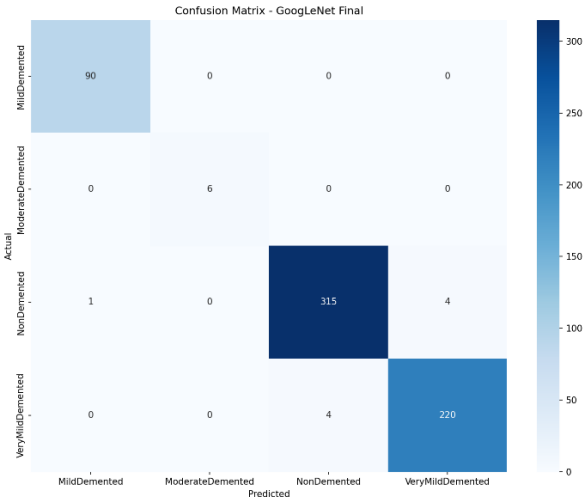

圖 4-11 GoogLeNet Confusion Matrix

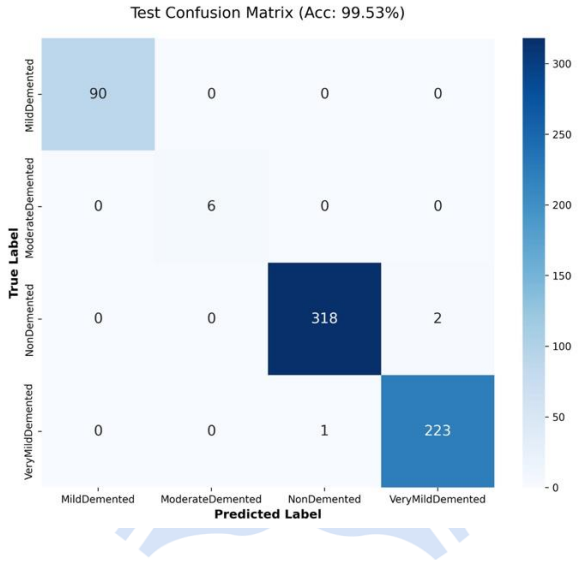

圖 4-12 ConvNeXt Confusion Matrix

表 4-1 各模型效能指標

Model	Val acc(%)	Test acc(%)	Test loss	Test F1(%)
AlzheimerCNN2	87.00	88.10	0.299	87.70
Resnet50	97.70	98.40	0.058	99.00
Resnet101	98.80	97.80	0.068	98.40
Efficientnet-B0	90.60	90.90	0.24	93.30
GoogLeNet	97.70	98.60	0.051	99.10
ConvNeXt - Tiny	**99.38**	**99.53**	**0.0274**	**99.72**

表 4-2 各模型綜合比較

Model	Enhance	Test acc(%)	Test F1(%)
AlzheimerCNN2	增加兩層 convolutions，提高 dropout、epochs，降 learning rate	88.1	87.7
Resnet50	transfer learning + scheduler + data augmentation	98.4	99
Resnet101	transfer learning + scheduler + data augmentation + LeakyReLU	97.8	98.4
Efficientnet	transfer learning + scheduler + data augmentation	90.9	93.3
GoogLeNet	transfer learning + scheduler + data augmentation	98.6	99.1
ConvNeXt - Tiny	transfer learning + data augmentation + 降低最後全連接層 + 調整 Weighted Loss	**99.53**	**99.72**

4.3 Grad-CAM

本研究透過 Grad-CAM 技術將 ConvNeXt-Tiny 模型的決策邏輯視覺化，實驗結果證實模型具備極高的臨床特徵辨識能力。綜合分析四類影像之熱力圖可以觀察到，模型的注意力焦點並非隨機分佈，而是精準地鎖定在與阿茲海默症病理高度相關的關鍵區域，這有效解決了深度學習模型長期以來被視為黑盒子的信任問題。

在失智症樣本（Mild, Moderate, VeryMild）圖 4-14 至圖 4-16 中，熱力圖顯示模型高度關注側腦室周邊以及顳葉內側的海馬迴區域，如與圖 4-17 所標示海馬迴在 MRI 影響中位置高度重疊。這與醫學常理相符：阿茲海默症的主要特徵

即為腦室擴張引起的腦組織受壓迫以及海馬迴萎縮。特別是在 ModerateDemented 的樣本中，由於病徵較為顯著，模型的激活區域呈現出更為集中且強烈的紅色訊號，顯示模型對於嚴重病變具有極高的辨識信心。

而在健康對照組中，模型的激活區域相較於失智組顯得更為分散，主要落在一般的腦部結構邊緣，並未出現針對萎縮病徵的集中特徵點。這組比對結果具體證明了模型已成功學會區分生理性腦萎縮與病理性病變之間的細微差異。綜上所述，本系統不僅在量化指標上取得佳績，其決策依據更符合放射科醫師的臨床直覺，具備成為醫療輔助診斷工具的實戰價值。

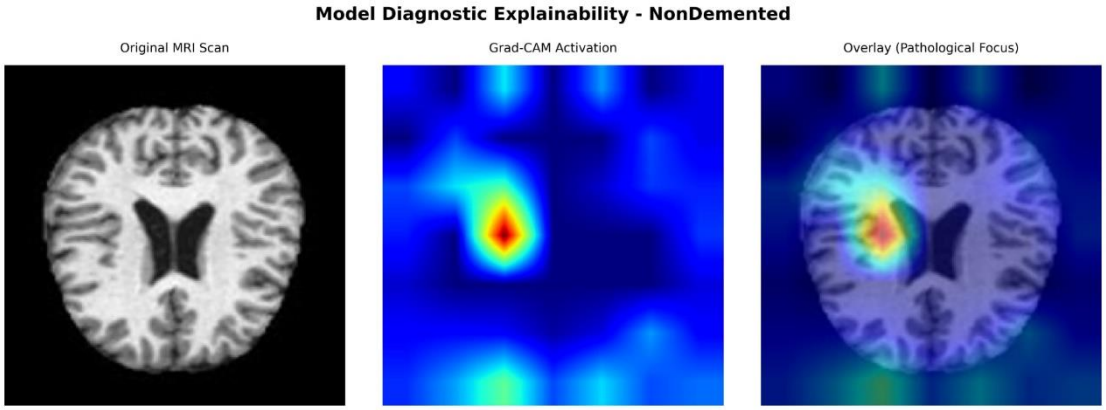

圖 4-13 NonDemented Heatmap

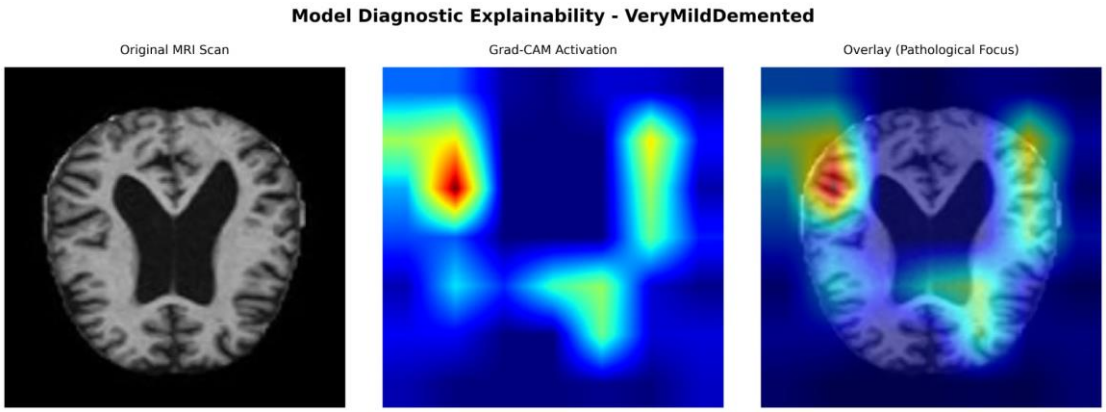

圖 4-14 VeryMildDemented Heatmap

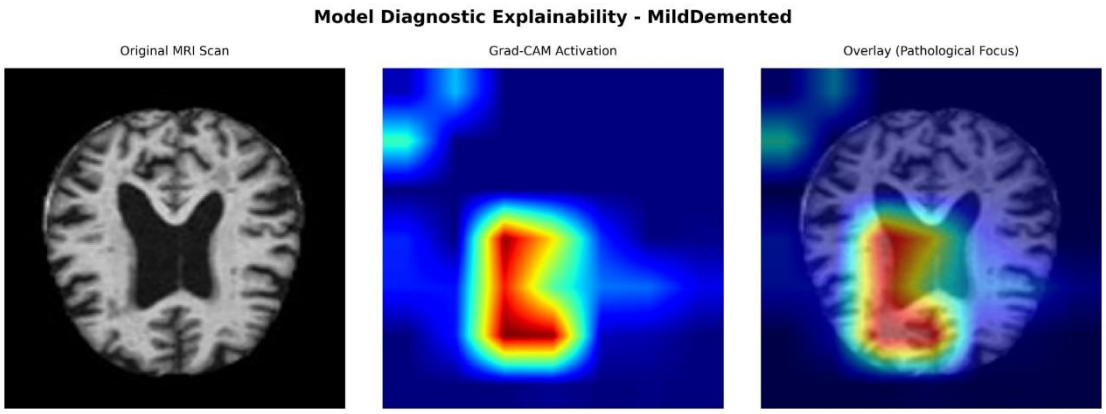

圖 4-15 MildDemented Heatmap

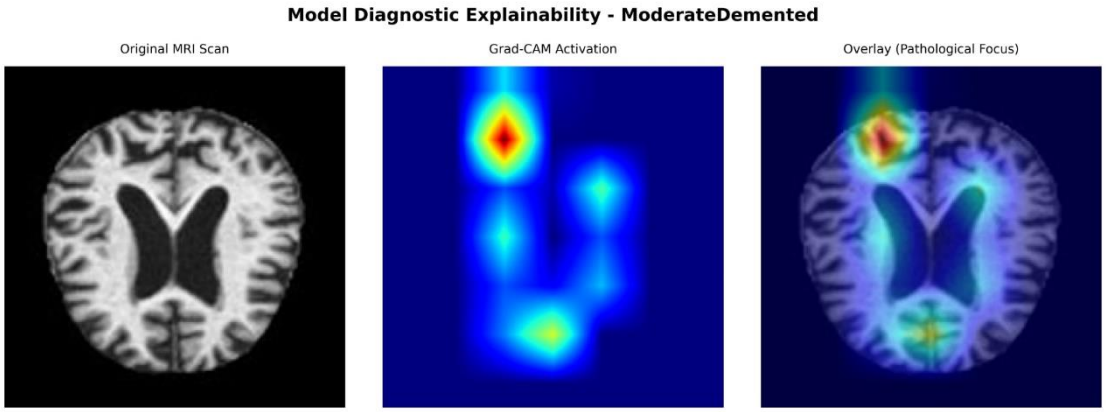

圖 4-16 ModerateDemented Heatmap

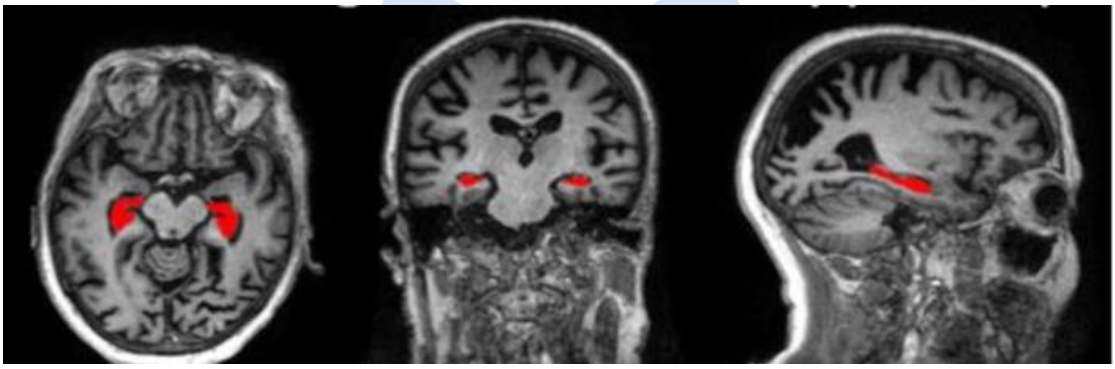

圖 4-17 The location of the hippocampus in the brain

第五章 結論

5.1 研究總結

本研究成功開發並評估了一套基於深度卷積神經網路的阿茲海默症 MRI 影像分類系統。透過對比 AlzheimerCNN2、ResNet、GoogLeNet、EfficientNet 及 ConvNeXt 等多種經典與現代架構，實驗結果顯示，現代化純卷積網路 ConvNeX 在結合遷移學習與特定優化策略後，展現出最卓越的性能。該模型在獨立測試集中取得了 99.53% 的準確率與 99.72%的 Macro F1-Score，顯著優於其他對比模型，證實了其在自動化輔助診斷中的高度潛力。

5.2 技術貢獻與發現

本研究之核心技術貢獻與實驗觀察歸納如下：

(1) 優化不平衡數據診斷：針對醫學影像中常見的類別不平衡問題，本研究導入了 Weighted Cross-Entropy Loss。實驗證實，透過將中度失智症（Moderate Demented）之損失權重提升，能有效消除模型對多數類別的預測偏誤，達成少數類別零漏診的目標。

(2) 動態學習率之重要性：導入餘弦退火法有效解決了訓練後期的驗證指標震盪問題。透過學習率的平滑衰減，模型得以在權重空間中進行更精細的微調，從而精準捕捉早期失智症（Very Mild）與健康大腦（NonDemented）之間微小的灰階特徵差異。

(3) 架構選型優勢：實驗數據顯示，並非網路層級越深，如 ResNet101 會效能越佳。具備較大感受野與先進正規化技術的 ConvNeXt 架構，在處理具備高度結構化特徵的腦部 MRI 影像時，展現了更優異的特徵提取效率與泛化穩定性。

5.3 未來展望

儘管本研究在單模態影像分類上已取得極佳成果，未來仍有值得深入探討臨床實測驗證，將模型應用於更多樣化的臨床數據集，以驗證其在不同掃描設備與族群背景下的穩健性。

參考資料

[1] C. R. Jack Jr et al., "MRI in Alzheimer's disease," The Lancet Neurology, vol. 8, no. 12, pp. 1167-1179, Dec. 2009.

[2] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," Proceedings of the IEEE, vol. 86, no. 11, pp. 2278-2324, Nov. 1998.

[3] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. Advances in Neural Information Processing Systems, 25, 1097-1105.

[4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770-778.

[5] M. Tan and Q. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in Proceedings of the 36th International Conference on Machine Learning (ICML), 2019, pp. 6105-6114.

[6] C. Szegedy et al., "Going deeper with convolutions," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015, pp. 1-9.

[7] Z. Liu, H. Mao, C. Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, "A ConvNet for the 2020s," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022, pp. 11976-11986.

[8] P. Singh, "Alzheimer's Dataset (4 class of Images)," Kaggle, 2021. [Online]. Available: https://www.kaggle.com/datasets/preetpalsingh25/alzheimers-dataset-4-class-of-images. [Accessed: Apr. 14, 2026].